

Корисні посилання:

- Датасети літер:

- A-Z Handwritten Alphabets (Kaggle)
- EMNIST Letters

```
def load_and_prepare_data():  
    print(f"[{datetime.now().strftime('%H:%M:%S')}] Завантаження датасету A-Z...")  
  
    # завантажуюємо CSV (знаходиться в моїй папці з д/з)  
    data = pd.read_csv("A_Z Handwritten Data.csv").values
```

**Файл A_Z Handwritten Data.csv розміром 600 МБ
я зберігаю в папці з проектом.**

Набір даних A_Z Handwritten Data.csv містить 26 папок (від A до Z) з
рукописними зображеннями розміром 28*28 пікселів.


Таблиця експериментів

	№ 1
Прихований шар	64
Швидкість	0,1
Епохи	500

Результат:

Час	12 хв
Втрата	0,9464
Точність	0,7641

	precision	recall	f1-score	support
0	0.65	0.80	0.72	2806
1	0.85	0.54	0.66	1673
2	0.82	0.88	0.85	4742
3	0.83	0.57	0.67	2044
4	0.80	0.68	0.74	2214
→ 5	0.00	0.00	0.00	231
6	0.90	0.22	0.35	1183
7	0.81	0.12	0.21	1466
→ 8	0.00	0.00	0.00	237
9	0.57	0.23	0.33	1668
10	0.86	0.12	0.21	1132
11	0.77	0.87	0.82	2319
12	0.76	0.84	0.80	2487
13	0.60	0.80	0.68	3756
14	0.86	0.96	0.91	11629
15	0.73	0.89	0.80	3868
16	0.89	0.25	0.39	1159
17	0.62	0.58	0.60	2296
18	0.82	0.93	0.87	9556
19	0.77	0.93	0.84	4447



Передбачення моделі



- 1) Погана матриця плутанини
- 2) Великий час навчання моделі = 12 хв
- 3) літери з індексом 5 та 8 - модель жодного разу не передбачила цей клас.
причина: у датасеті A-Z Handwritten Letters - різна кількість прикладів для літер від 1000 до 50 000

```
116 def balance_dataset(X, y): 1 usage
117     # Балансування дасету: вирівнює кількість прикладів для всіх класів
118
119     # Створюємо два порожні списки для збереження збалансованих даних
120     X_balanced, y_balanced = [], []
121
122     # Рахуємо кількість прикладів для кожного класу і знаходимо найменшу кількість
123     # (це буде цільовий розмір вибірки для кожного класу)
124     min_count = min(np.bincount(y))
125
126     # Проходимо по кожному унікальному класу в мітках
127     for cls in np.unique(y):
128         # Вибираємо всі приклади X, що належать до поточного класу cls
129         X_cls = X[y == cls]
130
131         # Вибираємо відповідні мітки (усі вони дорівнюють cls)
132         y_cls = y[y == cls]
133
134         # Балансуємо дані цього класу:
135         # - Якщо прикладів більше за min_count → undersampling (беремо підмножину)
136         # - Якщо прикладів менше за min_count → oversampling (беремо з повторенням)
137         X_res, y_res = resample(
138             *arrays: X_cls,          # дані класу
139             y_cls,                  # мітки класу
140             replace=len(y_cls) < min_count, # якщо клас рідкісний → дозволяємо дублювати
```


-- ПЕРЦЕПТРОН ДЛЯ РОЗПІЗНАВАННЯ ЛІТЕР (A-Z) --

[20:18:08] Завантаження датасету A-Z...

[20:18:31] Розподіл класів до балансування: Counter({np.int64(14): 57825, np.int64(18): 48419, np.int64(20): 29008, np.int64(19): 29008, np.int64(17): 29008, np.int64(15): 29008, np.int64(16): 29008, np.int64(13): 29008, np.int64(12): 29008, np.int64(11): 29008, np.int64(10): 29008, np.int64(9): 29008, np.int64(8): 29008, np.int64(7): 29008, np.int64(6): 29008, np.int64(5): 29008, np.int64(4): 29008, np.int64(3): 29008, np.int64(2): 29008, np.int64(1): 29008, np.int64(0): 29008})

[20:18:32] Розподіл класів після балансування: Counter({np.int64(0): 1120, np.int64(1): 1120, np.int64(2): 1120, np.int64(3): 1120, np.int64(4): 1120, np.int64(5): 1120, np.int64(6): 1120, np.int64(7): 1120, np.int64(8): 1120, np.int64(9): 1120, np.int64(10): 1120, np.int64(11): 1120, np.int64(12): 1120, np.int64(13): 1120, np.int64(14): 1120, np.int64(15): 1120, np.int64(16): 1120, np.int64(17): 1120, np.int64(18): 1120, np.int64(19): 1120, np.int64(20): 1120})

Параметри моделі:

- Розмір вхідного шару: 784
- Розмір прихованого шару: 64
- Розмір вихідного шару: 26
- Швидкість навчання: 0.1

[20:18:33] Епоха 1/500 - Втрата: 3.3785 - Точність на валідації: 0.0582

[20:18:39] Епоха 51/500 - Втрата: 2.6014 - Точність на валідації: 0.5024

[20:18:44] Епоха 101/500 - Втрата: 2.1877 - Точність на валідації: 0.6186

[20:18:49] Епоха 151/500 - Втрата: 1.8777 - Точність на валідації: 0.6707

[20:18:55] Епоха 201/500 - Втрата: 1.6407 - Точність на валідації: 0.7054

[20:19:00] Епоха 251/500 - Втрата: 1.4586 - Точність на валідації: 0.7265

[20:19:07] Епоха 301/500 - Втрата: 1.3177 - Точність на валідації: 0.7440

[20:19:13] Епоха 351/500 - Втрата: 1.2075 - Точність на валідації: 0.7539

[20:19:19] Епоха 401/500 - Втрата: 1.1199 - Точність на валідації: 0.7677

[20:19:25] Епоха 451/500 - Втрата: 1.0491 - Точність на валідації: 0.7758

[20:19:31] Епоха 500/500 - Втрата: 0.9921 - Точність на валідації: 0.7825

Точність на тестовому наборі: 0.7771

Модель обробляє кількість прикладів кожного класу (кожної літери) по найменшій величині, в даному випадку 1120. Таким чином, замість 57 тисяч прикладів - модель обробляє тільки 1120.

Застосовуємо балансування


	№ 2
Прихований шар	64
Швидкість	0,1
Епохи	500

Результат:

Час	2 хв
Втрата	0,99
Точність	0,78

Звіт про класифікацію:

	precision	recall	f1-score	support
0	0.67	0.79	0.73	203
1	0.78	0.75	0.76	206
2	0.84	0.83	0.83	223
3	0.85	0.79	0.82	231
4	0.79	0.64	0.71	222
5	0.84	0.92	0.88	210
6	0.85	0.79	0.82	229
7	0.67	0.69	0.68	209
8	0.85	0.93	0.89	231
9	0.68	0.68	0.68	232
10	0.69	0.76	0.72	248
11	0.84	0.88	0.86	238
12	0.77	0.86	0.82	220
13	0.70	0.59	0.64	249
14	0.76	0.85	0.80	211
15	0.76	0.83	0.79	213
16	0.79	0.79	0.79	204
17	0.74	0.56	0.64	226
18	0.90	0.82	0.86	225
19	0.77	0.84	0.80	232
20	0.74	0.76	0.75	237
21	0.84	0.90	0.87	219
22	0.77	0.77	0.77	239
23	0.74	0.74	0.74	226
24	0.73	0.76	0.75	212
25	0.89	0.71	0.79	229



Передбачення моделі



- 1) Гарна матриця плутанини, вся діагональ - темна
- 2) Передбачення моделі - покращується
- 3) Швидкий час навчання моделі = 2 хв
- 4) Всі літери - модель передбачає, ніде немає нулів


Зменшуємо швидкість до 0,01
мета - досягти втрат близько до нуля.
результат - негативний.

	№ 3
Прихований шар	64
Швидкість	0,01
Епохи	500

Результат:

Час	2 хв
Втрата	2,63
Точність	0,50

```
-- ПЕРЦЕПТРОН ДЛЯ РОЗПІЗНАВАННЯ ЛІТЕР (A-Z) --
[20:43:07] Завантаження датасету A-Z...
[20:43:28] Кількість прикладів кожного класу до балансування: Counter({'n': 1, 's': 1, 'z': 1, 'f': 1, 'j': 1, 'N': 1, 'K': 1, 'W': 1, 'R': 1, 'L': 1})
[20:43:30] Кількість прикладів кожного класу після балансування: Counter({'n': 26, 's': 26, 'z': 26, 'f': 26, 'j': 26, 'N': 26, 'K': 26, 'W': 26, 'R': 26, 'L': 26})
Параметри моделі:
- Розмір вхідного шару: 784
- Розмір прихованого шару: 64
- Розмір вихідного шару: 26
- Швидкість навчання: 0.01
[20:43:30] Епоха 1/500 - Втрата: 3.4229 - Точність на валідації: 0.0486
[20:43:36] Епоха 51/500 - Втрата: 3.2609 - Точність на валідації: 0.0690
[20:43:42] Епоха 101/500 - Втрата: 3.1463 - Точність на валідації: 0.1132
[20:43:47] Епоха 151/500 - Втрата: 3.0557 - Точність на валідації: 0.1779
[20:43:53] Епоха 201/500 - Втрата: 2.9788 - Точність на валідації: 0.2486
[20:43:59] Епоха 251/500 - Втрата: 2.9106 - Точність на валідації: 0.3290
[20:44:05] Епоха 301/500 - Втрата: 2.8484 - Точність на валідації: 0.3879
[20:44:10] Епоха 351/500 - Втрата: 2.7906 - Точність на валідації: 0.4313
[20:44:15] Епоха 401/500 - Втрата: 2.7362 - Точність на валідації: 0.4631
[20:44:21] Епоха 451/500 - Втрата: 2.6845 - Точність на валідації: 0.4857
[20:44:26] Епоха 500/500 - Втрата: 2.6361 - Точність на валідації: 0.5034
Точність на тестовому наборі: 0.4969
```



- 1) Матриця плутанини - стає гірше
- 2) Передбачення моделі - стає гірше
- 3) Втрата - стає гірше
- 4) Точність - стає гірше


Збільшуємо кількість нейронів у прихованому шарі до 256
мета - досягти втрат близько до нуля.
результат - позитивний.

	№ 4
Прихований шар	256
Швидкість	0,1
Епохи	500

Результат:

Час	3 хв
Втрата	0,76
Точність	0,80

було 0,99 (№ 2)



```
-- ПЕРЦЕПТРОН ДЛЯ РОЗПІЗНАВАННЯ ЛІТЕР (A-Z) --
[20:48:54] Завантаження датасету A-Z...
[20:49:17] Кількість прикладів кожного класу до балансування: Counter({n: 1})
[20:49:18] Кількість прикладів кожного класу після балансування: Counter({n: 1})
Параметри моделі:
- Розмір вхідного шару: 784
- Розмір прихованого шару: 256
- Розмір вихідного шару: 26
- Швидкість навчання: 0.1
[20:49:19] Епоха 1/500 - Втрата: 3.3936 - Точність на валідації: 0.0252
[20:49:35] Епоха 51/500 - Втрата: 2.3646 - Точність на валідації: 0.6023
[20:49:50] Епоха 101/500 - Втрата: 1.7701 - Точність на валідації: 0.6765
[20:50:04] Епоха 151/500 - Втрата: 1.4190 - Точність на валідації: 0.7170
[20:50:19] Епоха 201/500 - Втрата: 1.2038 - Точність на валідації: 0.7440
[20:50:35] Епоха 251/500 - Втрата: 1.0638 - Точність на валідації: 0.7610
[20:50:50] Епоха 301/500 - Втрата: 0.9673 - Точність на валідації: 0.7720
[20:51:05] Епоха 351/500 - Втрата: 0.8973 - Точність на валідації: 0.7819
[20:51:20] Епоха 401/500 - Втрата: 0.8443 - Точність на валідації: 0.7891
[20:51:35] Епоха 451/500 - Втрата: 0.8026 - Точність на валідації: 0.7967
[20:51:50] Епоха 500/500 - Втрата: 0.7695 - Точність на валідації: 0.8017
Точність на тестовому наборі: 0.8008
```



- 1) Матриця плутанини - покращується
- 2) Передбачення моделі - покращується
- 3) Точність - гарна

4) Втрата - покращується на 20 % відносно експерименту № 2 (швидкість=0,1) (епохи =500)

5) час збільшується на 1 хвилину, але це все одно краще експерименту № 1 де було 12 хв

Збільшуємо кількість епох до 1000


мета - досягти втрат близько до нуля.
результат - позитивний.

	№ 5
Прихований шар	256
Швидкість	0,1
Епохи	1000

Результат:

Час	5 хв	було 3 хв
Втрата	0,60	було 0,76
Точність	0,83	було 0,80

```
-- ПЕРЦЕПТРОН ДЛЯ РОЗПІЗНАВАННЯ ЛІТЕР (A-Z) --
[20:55:15] Завантаження датасету A-Z...
[20:55:36] Кількість прикладів кожного класу до балансування: Counter({np.int64(0): 26, np.int64(1): 26, np.int64(2): 26, np.int64(3): 26, np.int64(4): 26, np.int64(5): 26, np.int64(6): 26, np.int64(7): 26, np.int64(8): 26, np.int64(9): 26, np.int64(10): 26, np.int64(11): 26, np.int64(12): 26, np.int64(13): 26, np.int64(14): 26, np.int64(15): 26, np.int64(16): 26, np.int64(17): 26, np.int64(18): 26, np.int64(19): 26, np.int64(20): 26, np.int64(21): 26, np.int64(22): 26, np.int64(23): 26, np.int64(24): 26, np.int64(25): 26})
[20:55:37] Кількість прикладів кожного класу після балансування: Counter({np.int64(0): 1, np.int64(1): 1, np.int64(2): 1, np.int64(3): 1, np.int64(4): 1, np.int64(5): 1, np.int64(6): 1, np.int64(7): 1, np.int64(8): 1, np.int64(9): 1, np.int64(10): 1, np.int64(11): 1, np.int64(12): 1, np.int64(13): 1, np.int64(14): 1, np.int64(15): 1, np.int64(16): 1, np.int64(17): 1, np.int64(18): 1, np.int64(19): 1, np.int64(20): 1, np.int64(21): 1, np.int64(22): 1, np.int64(23): 1, np.int64(24): 1, np.int64(25): 1})
Параметри моделі:
- Розмір вхідного шару: 784
- Розмір прихованого шару: 256
- Розмір вихідного шару: 26
- Швидкість навчання: 0.1
[20:55:38] Епоха 1/1000 - Втрата: 3.4051 - Точність на валідації: 0.0476
[20:55:53] Епоха 51/1000 - Втрата: 2.3650 - Точність на валідації: 0.5800
[20:56:08] Епоха 101/1000 - Втрата: 1.7794 - Точність на валідації: 0.6674
[20:56:23] Епоха 151/1000 - Втрата: 1.4255 - Точність на валідації: 0.7105
[20:56:38] Епоха 201/1000 - Втрата: 1.2084 - Точність на валідації: 0.7392
[20:56:53] Епоха 251/1000 - Втрата: 1.0677 - Точність на валідації: 0.7562
[20:57:08] Епоха 301/1000 - Втрата: 0.9707 - Точність на валідації: 0.7704
[20:57:23] Епоха 351/1000 - Втрата: 0.9004 - Точність на валідації: 0.7802
[20:57:38] Епоха 401/1000 - Втрата: 0.8470 - Точність на валідації: 0.7914
[20:57:52] Епоха 451/1000 - Втрата: 0.8050 - Точність на валідації: 0.7953
[20:58:07] Епоха 501/1000 - Втрата: 0.7709 - Точність на валідації: 0.8013
[20:58:22] Епоха 551/1000 - Втрата: 0.7426 - Точність на валідації: 0.8072
[20:58:37] Епоха 601/1000 - Втрата: 0.7187 - Точність на валідації: 0.8099
[20:58:52] Епоха 651/1000 - Втрата: 0.6980 - Точність на валідації: 0.8132
[20:59:07] Епоха 701/1000 - Втрата: 0.6799 - Точність на валідації: 0.8156
[20:59:22] Епоха 751/1000 - Втрата: 0.6638 - Точність на валідації: 0.8201
[20:59:37] Епоха 801/1000 - Втрата: 0.6494 - Точність на валідації: 0.8223
[20:59:52] Епоха 851/1000 - Втрата: 0.6364 - Точність на валідації: 0.8242
[21:00:06] Епоха 901/1000 - Втрата: 0.6245 - Точність на валідації: 0.8269
[21:00:22] Епоха 951/1000 - Втрата: 0.6135 - Точність на валідації: 0.8308
[21:00:36] Епоха 1000/1000 - Втрата: 0.6036 - Точність на валідації: 0.8328
```



- 1) Матриця плутанини - покращується чуть-чуть
- 2) Передбачення моделі - покращується (всі зелені)
- 3) Втрата - покращується (зменшення до 0,60)
- 4) Точність - покращується (збільшення до 0,83)


5) час збільшується на 2хвилини, але це все одно краще експерименту № 1 де було 12 хв

Зменшуємо швидкість до 0,05
мета - досягти втрат близько до нуля.
результат - негативний.

	№ 6
Прихований шар	256
Швидкість	0,05
Епохи	1000

Результат:

Час	5 хв	було 5 хв
Втрата	0,76	було 0,60
Точність	0,80	було 0,83



```
-- ПЕРЦЕПТРОН ДЛЯ РОЗПІЗНАВАННЯ ЛІТЕР (A-Z) --
[21:05:32] Завантаження датасету A-Z...
[21:05:54] Кількість прикладів кожного класу до балансування: Counter({'np.int
[21:05:56] Кількість прикладів кожного класу після балансування: Counter({'np.
Параметри моделі:
- Розмір вхідного шару: 784
- Розмір прихованого шару: 256
- Розмір вихідного шару: 26
- Швидкість навчання: 0.05
[21:05:57] Епоха 1/1000 - Втрата: 3.3881 - Точність на валідації: 0.0381
[21:06:11] Епоха 51/1000 - Втрата: 2.7546 - Точність на валідації: 0.4681
[21:06:26] Епоха 101/1000 - Втрата: 2.3420 - Точність на валідації: 0.5977
[21:06:41] Епоха 151/1000 - Втрата: 2.0126 - Точність на валідації: 0.6549
[21:06:56] Епоха 201/1000 - Втрата: 1.7575 - Точність на валідації: 0.6848
[21:07:11] Епоха 251/1000 - Втрата: 1.5615 - Точність на валідації: 0.7055
[21:07:26] Епоха 301/1000 - Втрата: 1.4101 - Точність на валідації: 0.7213
[21:07:40] Епоха 351/1000 - Втрата: 1.2916 - Точність на валідації: 0.7347
[21:07:56] Епоха 401/1000 - Втрата: 1.1975 - Точність на валідації: 0.7464
[21:08:12] Епоха 451/1000 - Втрата: 1.1216 - Точність на валідації: 0.7553
[21:08:26] Епоха 501/1000 - Втрата: 1.0595 - Точність на валідації: 0.7630
[21:08:41] Епоха 551/1000 - Втрата: 1.0079 - Точність на валідації: 0.7685
[21:08:56] Епоха 601/1000 - Втрата: 0.9643 - Точність на валідації: 0.7740
[21:09:12] Епоха 651/1000 - Втрата: 0.9272 - Точність на валідації: 0.7790
[21:09:27] Епоха 701/1000 - Втрата: 0.8951 - Точність на валідації: 0.7835
[21:09:41] Епоха 751/1000 - Втрата: 0.8672 - Точність на валідації: 0.7867
[21:09:57] Епоха 801/1000 - Втрата: 0.8426 - Точність на валідації: 0.7910
[21:10:12] Епоха 851/1000 - Втрата: 0.8207 - Точність на валідації: 0.7940
[21:10:27] Епоха 901/1000 - Втрата: 0.8012 - Точність на валідації: 0.7976
[21:10:42] Епоха 951/1000 - Втрата: 0.7836 - Точність на валідації: 0.8019
[21:10:57] Епоха 1000/1000 - Втрата: 0.7679 - Точність на валідації: 0.8039
```



- 1) Матриця плутанини - гірше чуть-чуть
- 2) Передбачення моделі - гірше (з'явилися червоні)
- 3) Втрата - гірше
- 4) Точність - гірше

Результат - швидкість зменшувати немає сенсу. Краще залишити 0,1. Найкращий варіант: № 5


Таблиця експериментів

	№ 1	№ 2	№ 3	№ 4	№ 5	№ 6
Прихований шар	64	64	64	256	256	256
Швидкість	0,1	0,1	0,01	0,1	0,1	0,05
Епохи	500	500	500	500	1000	1000

Результат:

Час	12 хв	2 хв	2 хв	3 хв	5 хв	5 хв
Втрата	0,9464	0,99	2,63	0,76	0,60	0,76
Точність	0,7641	0,78	0,50	0,80	0,83	0,80

Передбачення моделі для всіх 26 літер



Таблиця експериментів

	№ 1	№ 2	№ 3	№ 4	№ 5	№ 6	№ 7	№ 8	№ 9
Прихований шар	64	64	64	256	256	256	256	256	64
Швидкість	0,1	0,1	0,01	0,1	0,1	0,5	1	2	0,01
Епохи	500	500	500	500	1000	1000	1000	1000	10000

Результат:

Час	12 хв	2 хв	2 хв	3 хв	5 хв	6 хв	6 хв	6 хв	23 хв
Втрата	0,9464	0,99	2,63	0,76	0,60	0,30	0,16	0,05	0,71
Точність	0,7641	0,78	0,50	0,80	0,83	0,88	0,90	0,92	0,82

Передбачення моделі для всіх 26 літер



25 - зелених літер
1 - червона літера